Afonso Lucas

Engenheiro de IA & Desenvolvedor de Software

LinkedIn | GitHub | Medium | ifonso.developer@gmail.com

Manaus, Brasil (GMT - 4) — Disponível para Trabalho Remoto

Engenheiro de inteligência artificial aplicada. Atuo em todo o ciclo dos produtos que integram IA — da engenharia de requisitos e ideação até a implantação em produção — apoiado em base sólida de engenharia de software: nos últimos 4 anos participei ativamente da concepção ao desenvolvimento de diversos produtos. Hoje construo pipelines de RAG, arquiteturas com agentes e integrações com LLMs em uma plataforma corporativa, projetando em torno dos trade-offs que aparecem de fato em produção: qualidade de geração, custo de inferência e latência. Atualmente trabalho em P&D de IA aplicada à manufatura inteligente (Indústria 4.0).

Experiência

Pesquisador e Desenvolvedor de Inteligência Artificial - (P&D) Hub de Tecnologia e Inovação (Manaus, Brasil)

(2024 – Atualmente)

- **Projetei** e **implementei** a camada de IA de uma plataforma corporativa do zero à produção, desenvolvendo pipelines de RAG e backends orientados a eventos (Python, FastAPI, RabbitMQ, MongoDB, Qdrant).
- **Reduzi** em **~50%** os **custos operacionais** de inferência de LLMs otimizando estratégias de cache e filtragem de dados, sem perda mensurável de qualidade.
- Criei APIs REST e bibliotecas (LLMaaS) que expõem modelos de linguagem para consumo interno de outras equipes, integrando motores de inferência local como *llama.cpp*.
- Desenvolvi integrações resilientes com provedores de IA (OpenAI, Anthropic, Together AI), implementando sistemas de fallback, rate limiting e tratamento de erros.
- Capacitei agentes autônomos implementando Tool Calling e servidores MCP (Model Context Protocol), permitindo que agentes executem ações reais nos sistemas da empresa.
- **Criei uma metodologia própria de avaliação de LLMs**, combinando métricas de mercado para mitigar comportamentos indesejados e ranquear modelos de forma reprodutível.
- **Garanti a estabilidade da plataforma** desenvolvendo testes unitários (pytest) e ferramentas de teste de carga para simular cenários de estresse pré-deploy.
- **Acelerei o ciclo de entregas** adotando *Spec-Driven Development* (SDD) e ferramentas de desenvolvimento assistido por IA (Claude Code, Codex), utilizando grafos de conhecimento (*graphify*) para manter a precisão do contexto em bases de código extensas.
- **Atuei como ponte entre tech e business**, traduzindo decisões arquiteturais e resultados complexos para stakeholders, além de manter alto padrão de código via GitFlow, Code Reviews e registros de decisões técnicas.

Backend & iOS Developer - (P&D) Instituto de Pesquisa Eldorado

(2022 – 2024)

- Projetei e implementei **APIs REST** e arquiteturas de microsserviços para aplicativos com alto volume de usuários.
- Desenvolvi pipelines de processamento de dados em larga escala alimentando sistemas de recomendação baseados em IA.
- Modelei e mantive esquemas de banco relacional e não-relacional (**PostgreSQL**, MongoDB) dando suporte a essas APIs.
- Atuei ativamente em **code reviews** e documentação técnica, elevando o padrão de qualidade e reprodutibilidade do time.

Prêmios e Reconhecimento

WWDC22 Swift Student Challenge Winner

2022 – Apple Inc.

Pesquisa e Publicações

- Large language models as a decision-making core for semantic capability check in asset administration shell-based intelligent manufacturing.

  The International Journal of Advanced Manufacturing Technology.

  https://doi.org/10.1007/s00170-026-18632-2

- A Modular Active–Reactive AAS Architecture for Mass-Customized Production: Validation on an Industrial-Grade Robotic Screwdriving Demonstrator.

  Sensors

  https://doi.org/10.3390/s26175523

Habilidades Técnicas

- **Linguagens:** Python, TypeScript, JavaScript, Go, C/C++, Java, Swift.
- **Frontend:** React, TypeScript, HTML, CSS, Tailwind CSS, Vite, componentização, hooks customizados, consumo de APIs REST e WebSocket, validação de dados com Zod.
- **Backend & APIs:** FastAPI, Express, NestJS, Django, Flask, asyncio, Pydantic, APIs REST, GraphQL, gRPC, WebSocket, HTTP, autenticação OAuth2/JWT, segurança de aplicações, RabbitMQ.
- **IA & LLM:** RAG em produção, MCP (Model Context Protocol), Tool Calling, LangChain, LangGraph, Fine-tuning (LoRA/QLoRA), Serving Local (llama.cpp, vLLM), Quantização, Evals/Métricas customizadas, OpenAI, Anthropic, Hugging Face.
- **Bancos de Dados & Vetoriais:** PostgreSQL, MongoDB, MySQL, Redis; Qdrant, Weaviate, pgvector.
- **Qualidade & Testes:** testes unitários automatizados com pytest, teste de carga, TDD, code review, depuração, documentação técnica e critérios de aceite.
- **Infra & DevOps:** Docker, Git, GitHub, GitLab, CI/CD, Grafana, Prometheus, AWS, Firebase, Vercel, Cloudflare, Railway, Linux.
- **Desenvolvimento assistido por IA:** Claude Code, Skills, Cursor, GitHub Copilot, spec-driven development (spec-kit).

- **Metodologias:** desenvolvimento ágil (Scrum, Kanban), GitFlow, **spec-driven development (SDD)**, priorização por critérios de aceite, registro de decisões técnicas.

Certificados

C2 Proficient EF English

2024 – EF English.

Backend & API Development

2024 – Freecodecamp.

App Development with Swift Certified User

2023 – Apple Inc.

Formação Acadêmica

Bacharelado em Engenharia de Computação

2022 – 2027 (previsto), Brasil
Universidade do Estado do Amazonas